

MATEMATIČKI FAKULTET

SEMINARSKI RAD
IZ TEHNIČKOG I NAUČNOG PISANJA

AI u astronomiji: otkrivanje egzoplaneta i analiza svemirskih podataka

Student
Kosta Čolović 27/2025

Profesor
dr Jelena Graovac

Beograd, januar 2026.

Sadržaj

1	Uvod	1
1.1	Problemi sa podacima u modernoj astronomiji	1
1.2	Veštačka inteligencija i mašinsko učenje	1
1.3	Uticaј na otkrivanje egzoplaneta	1
2	Tradicionalne metode i njihova ograničenja	1
2.1	Tranzitna fotometrija	1
2.2	Metoda kružne brzine	2
2.3	Spektroskopija	2
2.4	Problemi sa tradicionalnim metodama i motivacija iza AI sistema	2
3	AI metode fotometrijske analize	3
3.1	Klasičan ML (Random Forest, SVM, Logistička regresija)	3
3.2	Duboko učenje	3
3.2.1	CNN-ovi za tranzitnu detekciju	3
3.2.2	RNN-ovi i LSTM-ovi za vremenske serije	3
3.2.3	Autoenkoderi za detekciju anomalija	4
3.3	Visokoprecizni rezultati - Kepler i TESS	4
4	AI izvan fotometrije - spektroskopija i snimanje	4
4.1	Visokokontrastno snimanje i CNN-ovi	4
4.2	Spektralna unakrsna korelacija i ML (molekulska detekcija)	4
4.3	ML u uklanjanju zvezdane aktivnosti iz signala kružne brzine	4
4.4	Hibridni cevovodi	4
5	Obrada svemirskih podataka pomoću AI-a	5
5.1	Redukcija šuma	5
5.2	Izoštavanje svetlosnih krivih	5
5.3	Detekcija teleskopskih anomalija	5
5.4	Klasifikacija svemirskih objekata	5
5.5	Primena AI-a u kompresiji i filtriranju podataka u letelicama	5
5.6	Primena AI-a u teleskopima - JWST, Gaia, Euclid	6
6	Izazovi, rizici i interpretabilnost	6
6.1	AI modeli su crne kutije	6
6.2	Nepodudaranje sintetičkih i realnih podataka za treniranje	6
6.3	Disbalans među klasama (malo planeta, mnogo zvezda)	6
6.4	Alati za interpretaciju	6
6.5	Potreba za reproduktivnošću	7
7	Budućnost i zaključak	7

Sažetak

Obim podataka generisanih svemirskim i zemaljskim teleskopima raste svakodnevno. Ovo nameće potrebu za automatizacijom metoda analize. Ovo je posebno istaknuto u oblasti nauke o egzoplanetama, gde se detekcija vrši nad milijardama merenja, a tradicionalne tehnike postaju neefikasne. U ovom radu dat je pregled primene veštačke inteligence u otkrivanju egzoplaneta i obradi velikih skupova astronomske podataka. Razmotrene su klasične metode mašinskog učenja, kao i savremeni duboki neuronski modeli. Diskusija uključuje primene u analizi svetlosnih krivih, spektroskopiji, visokokontrastnom snimanju, smanjenju šuma, klasifikaciji, automatizovanom filtriranju podataka, kao i moguću budućnost ove tehnologije. Analizom skorašnjih dostignuća, ovaj rad ističe rastuću ulogu veštačke inteligencije kao ključnog alata u budućim astronomskim istraživanjima.

1. Uvod

1.1. Problemi sa podacima u modernoj astronomiji

Moderna astronomija je u prethodnim godinama ušla u tzv. eru *velikih podataka* (engl. Big data). Najnoviji svemirski teleskopi (Kepler, TESS, Gaia, JWST) generišu ogromnu količinu podataka - mnogo više nego što bi ljudi pouzdano mogli da obrade ručno. Iz ovog razloga se astronomija sve više oslanja na automatizovane metode za analizu velikih skupova podataka [1].

Devetogodišnja misija Kepler (2009-2018) rezultirala je otkrićem više hiljada potvrđenih egzoplaneta¹. Teleskop TESS (Transiting Exoplanet Survey Satellite), Keplerov naslednik, trenutno je u svemiru na produženim misijama i pokriva 400 puta veću površinu (gotovo celu nebesku sferu) [2, 3].

1.2. Veštačka inteligencija i mašinsko učenje

Veštačka inteligencija (kao i mašinsko učenje - skraćeno ML, jedno od njenih polja) ima sposobnost automatskog učenja obrazaca iz skupa podataka. Umesto eksplicitnog programiranja svakog pravila, ML sistemi donose zaključke o međusobnoj povezanosti objekata direktno iz zadatih primera. Ovo ih čini pogodnim za obradu kompleksnih astronomske signala, gde šum, varijabilnost i efekti mernih instrumenata često zamagljuju fizičke procese [1].

1.3. Uticaj na otkrivanje egzoplaneta

Detekcija planeta pomoću tranzitne fotometrije zahteva identifikovanje jako malih promena u intenzitetu svetlosti zvezda (često manje od 1%), sakrivenih među šumom u podacima. Tradicionalni algoritmi i ljudska provera ne mogu ispratiti nepregledne podatke o hiljadama zvezda koji se sakupljaju svakodnevno. Metode veštačke inteligencije (posebno mašinsko i duboko učenje) demonstrirale su superiornu osetljivost, povećanu uspešnost pri odbacivanju lažno-pozitivnih rezultata i mogućnost detekcije suptilnih tranzitnih signala koje tradicionalni cevovodi često propuste [4].

2. Tradicionalne metode i njihova ograničenja

2.1. Tranzitna fotometrija

Tranzit podrazumeva prolazak posmatrane planete između posmatrača i svoje zvezde. Ova metoda funkcioniše tako što se prate promene u svetlini zabeležene svetlosne krive, što predstavlja blago smanjenje intenziteta svetlosti posmatrane zvezde pri prolasku planete.

Tranzitna metoda može pomoći pri određivanju raznih karakteristika egzoplanete. Na primer, veličina orbite planete se može izračunati na osnovu vremena potrebnog za jednu punu revoluciju, dok se veličina planete može odrediti na osnovu promene u intenzitetu detektovane svetlosti zvezde. Takođe se može odrediti kompozicija atmosfere planete. Naime, deo svetlosti zvezde će proći kroz atmosferu, što izaziva disperziju. Na osnovu prirode ove disperzije, mogu se odrediti konkretni atmosferski elementi. Kompozicija atmosfere ključna je pri određivanju habitabilnosti planete (ona se dalje određuje kroz

¹Zanimljivo je da od preko 2600 egzoplaneta pronađenih teleskopom Kepler, samo jako mali procenat čine planete koje su kamenite (nalik zemlji, ali malo veće) i orbitiraju u nastanjivoj zoni svoje zvezde (gde voda u tečnom stanju može postojati).

veličinu orbite i temperaturu zvezde, što utiče na temperaturu površine same planete). NASA je do sada pronašla hiljade egzoplaneta posmatrajući planetarne tranzite [5, 6].

2.2. Metoda kružne brzine


Metoda kružne brzine (engl. Radial velocity method) oslanja se na Doplerov² efekat (jednačina 1), kao i na činjenicu da zvezda ne miruje dok planeta orbitira oko nje, već pravi blage pokrete pod uticajem gravitacije planete.

$$f' = f \sqrt{\frac{1 + \beta}{1 - \beta}}, \quad \beta = \frac{v}{c} \quad (1)$$

Ovo utiče na svetlosni spektar zvezde - ukoliko se kreće ka posmatraču, talasne dužine se skraćuju, odnosno postaju *plavije* (engl. blue-shift). Analogno, kod zvezde koja se udaljava od posmatrača, talasne dužine se izdužuju, tj. postaju *crvenije* (engl. red-shift). Ovakvi efekti se mere izuzetno osetljivim spektroskopima. Ovo je bila prva uspešna metoda za detektovanje egzoplaneta [7].

2.3. Spektroskopija

Spektroskopija je naučni metod proučavanja objekata i materijala na osnovu obrazaca talasnih dužina. Spektroskopijom se mogu otkriti brojne osobine posmatranog objekta. Ona je (zajedno sa snimanjem) jedna od najčešćih i najkorisnijih metoda u astronomiji. Dok nam snimci daju informacije o veličini, obliku i strukturi materije u svemiru, spektri otkrivaju ključne detalje poput temperature, kompozicije i kretanja. Na ovaj način možemo saznati hemijsku strukturu atmosfere egzoplanete. Spektar zračenja Sunca predstavljen je na slici 1 [8].



Slika 1: Spektar Sunčevog zračenja (viridiansolar.co.uk)

2.4. Problemi sa tradicionalnim metodama i motivacija iza AI sistema

- **Slabi signali** - Kao što je pomenuto ranije, tranziti egzoplaneta, naročito onih sličnih Zemlji, oko Sunčevih blizanaca³, rezultiraju izuzetno malim padovima u intenzitetu svetlosti (reda veličine 0.01%), što čini detekciju tradicionalnim metodama jako teškom [10, 1].
- **Zvezdani šum** - Svetlost zvezda prirodno varira (zbog pega, oscilacija i sl.), što lako može zamaskirati planetarne tranzite. Ovakav šum proizvodi obrasce koji su jako nepravilni i samim tim teški za modelovanje pomoću tradicionalnih metoda [10, 1].

²Christian Andreas Doppler, austrijski matematičar i fizičar.

³Sunčevim blizancima se nazivaju zvezde slične našem Suncu [9].

- **Ogromni skupovi podataka** - Misije poput Keplera i TESS sakupljaju milijarde fotometrijskih merenja, što proizvodi skupove podataka daleko prevelike za bilo koju vrstu manuelne inspekcije. Efikasna automatizovana analiza neophodna je za identifikaciju retkih tranzita, koji su često zakopani u ogromnim skupovima podataka [10, 1].
- **Potreba za ljudskom proverom** - Istorijski gledano, timovi astronoma morali su ručno da pregledaju svetlosne krive kako bi uspeali da isfiltriraju lažno pozitivne rezultate. Kako veličina skupova prikupljenih podataka raste, ovakav tip provere postaje neodrživ. Iz ovog razloga se javlja potreba za AI sistemima koji mogu značajno asistirati ljudskim ekspertima [10, 1].

3. AI metode fotometrijske analize

3.1. Klasičan ML (Random Forest, SVM, Logistička regresija)

Prve primene AI-a u detekciji egzoplaneta oslanjale su se na klasične ML algoritme, poput logističke regresije, SVM-a i Random Forest-a. Ovi algoritmi se koriste za obradu podataka ručno izvučenih iz svetlosnih krivih (tranzitna dubina, trajanje, odnos signala i šuma, metrika periodičnosti). Klasifikatori poput Random Forest-a pokazali su odlične performanse pri razdvajanju stvarnih planetarnih tranzita od lažno pozitivnih. Skorašnje komparativne studije pokazale su da pravilno istrenirani klasični ML modeli mogu značajno nadmašiti tradicionalne metode [11, 12].

3.2. Duboko učenje

3.2.1. CNN-ovi za tranzitnu detekciju

Pristupi koji uključuju duboko učenje (posebno konvolucione neuronske mreže - CNN) postali su dominantna metoda za fotometrijsku detekciju egzoplaneta. CNN-ovi rade direktno na normalizovanim svetlosnim krivim ili *fazno savijenim* (engl. phase-folded) tranzitnim signalima, automatski učeći relevantne parametre bez manuelnog podešavanja. Ovo im omogućava identifikaciju suptilnih i neregularnih tranzitnih oblika, koje je teško zabeležiti pomoću analitičkih modela. Studije pokazuju vrlo visoku klasifikacionu tačnost (98-99%) pri testiranju CNN modela na Kepler i TESS podacima⁴. Skorašnja istraživanja (2022-2025) potvrđuju da CNN modeli značajno smanjuju broj lažno pozitivnih rezultata u poređenju sa tradicionalnim metodama [12, 13].

3.2.2. RNN-ovi i LSTM-ovi za vremenske serije

Rekurentne (RNN) i Long Short-Term Memory (LSTM) mreže se takođe primenjuju u detekciji egzoplaneta, jer su pogodni za obradu sekvencijalnih podataka (poput svetlosnih krivih). Ovi modeli su dizajnirani da istaknu vremenske zavisnosti i dugoročne korelacije u skupovima podataka, što ih čini pogodnim za modelovanje periodičnih tranzitnih signala i zvezdane varijabilnosti. LSTM modeli su demonstrirali povećanu osetljivost prema neregularnim, kao i tranzitima velikog perioda. Ovo je posebno istaknuto u šumovitim skupovima podataka, gde je periodičnost manje očigledna. Skorašnje studije pokazuju njihovu korisnost kada se koriste kao komplement CNN modelima u hibridnim arhitekturama. U tabeli 1 prikazane su opisane metode zajedno sa svojim prednostima, kao i okolnostima u kojima se primenjuju [14, 15].

Metoda	Ključne prednosti	Tipična primena
Random Forest	Interpretabilnost i robusnost	Kepler svetlosne krive
CNN	Visoka tačnost u detekciji tranzita	Kepler i TESS
LSTM	Modelovanje vremenskih zavisnosti	Tranziti dugog perioda

Tabela 1: Pregled AI metoda u analizi egzoplanetarnih svetlosnih krivih

⁴Bitno je napomenuti da metričke vrednosti zavise od disbalansa klasa i izbora evaluacionih kriterijuma.

3.2.3. Autoenkoderi za detekciju anomalija

Tehnike nenadgledanog mašinskog učenja, poput autoenkodera, sve se više koriste za detekciju anomalija u fotometrijskim skupovima podataka. Autoenkoderi uče kompaktnu reprezentaciju „normalne“ zvezdane varijabilnosti i mogu označiti neobične obrasce, koji mogu odgovarati planetarnim tranzitima ili retkim astronomskim pojavama. Ovaj pristup je posebno značajan kada su označeni trening podaci ograničeni ili pristrasni. Skorašnji radovi ističu ulogu autoenkodera u pretprocesiranju, smanjenju šuma i odabiru kandidata za planetarne tranzite unutar velikih skupova podataka [14].

3.3. Visokoprecizni rezultati - Kepler i TESS

U više studija objavljenih između 2022. i 2025. godine, fotometrijski cevovodi bazirani na AI-u demonstrirali su konstantno visoke rezultate na podacima sa stvarnih misija. CNN i ensemble modeli trenirani na svetlosnim krivim dobijenim pomoću Keplera postižu klasifikacione tačnosti od preko 99%. Modeli su pritom pokazali sposobnost generalizacije prema podacima sa TESS-a, iako razlike u šumu i instrumentalnim karakteristikama često zahtevaju dodatnu adaptaciju ili ponovno treniranje. Ovi rezultati potvrđuju da AI metode nisu efikasne samo pri kontrolisanim eksperimentima, već i u realnim uslovima, što ih čini esencijalnim alatom u modernom otkrivanju egzoplaneta [12].

4. AI izvan fotometrije - spektroskopija i snimanje

4.1. Visokokontrastno snimanje i CNN-ovi

Cilj *visokokontrastnog snimanja* (engl. high-contrast imaging) je direktno posmatranje egzoplaneta ili cirkumstelarnih diskova⁵. Ovo se postiže umanjivanjem intenziteta svetlosti zvezde. U ovom kontekstu, CNN-ovi su posebno efektivni pri učenju prostornih obrazaca koji razlikuju slabe planetarne signale od šuma i instrumentalnih artifakta. Skorašnje studije pokazuju da CNN modeli mogu značajno nadmašiti klasične *pragove detekcije* (engl. detection thresholds) korišćenjem suptilnih prostorno-spektralnih korelacija u višedimenzionim skupovima podataka [17].

4.2. Spektralna unakrsna korelacija i ML (molekulska detekcija)

Tehnike spektralne unakrsne korelacije se često koriste za detekciju molekula u atmosferi egzoplanete. Ovo se ogleda u podudaranju teoretskog sa zabeleženim spektrom. Rakesh Nath-Ranga predložio je u svom radu iz 2024. godine hibridnu metodu, gde se mape unakrsne korelacije, proistekle iz spektroskopije, ubacuju kao ulaz u modele dubokog učenja, poput CNN-ova i konvolucionih LSTM-ova. Ovo omogućava osjetljiviju i robusniju detekciju egzoplaneta [18].

Slično, Emily Omayya Garvin je u radu iz 2024. godine uvela Machine Learning for Cross-Correlation Spectroscopy framework (MLCCS), koji primenjuje neuronske mreže direktno na unakrsno korelirane spektralne podatke. Ova metoda drastično povećava osjetljivost detekcije u odnosu na tradicionalne tzv. signal-to-noise-based metode [17].

4.3. ML u uklanjanju zvezdane aktivnosti iz signala kružne brzine

Zvezdana aktivnost često utiče na merenja kružne brzine. Modeli mašinskog učenja mogu naučiti kompleksne, nelinearne odnose između indikatora zvezdane aktivnosti i varijacija u kružnoj brzini. To znači da se ovi efekti mogu modelovati i uspešno ukloniti. Zoe De Beurs je u svom radu iz 2022. godine demonstrirala da neuronske mreže trenirane na zvezdanim spektrima mogu ukloniti signale izazvane aktivnošću zvezda, što povećava preciznost merenja kružne brzine i osjetljivost na egzoplanete manje mase [19].

4.4. Hibridni cevovodi

Ključni trend u modernoj egzoplanetarnoj spektroskopiji i snimanju je napredak tzv. hibridnih cevovoda, koji kombinuju metode bazirane na fizičkim principima i učenje zasnovano na podacima. Fizički

⁵Diskovi sačinjeni od prašine, gasa, asteroida i drugih objekata koji rotiraju oko zvezde [16].

modeli (Doppler shifts, atmospheric templates, cross-correlation functions) koriste se za pretprocesiranje i strukturiranje podataka, dok se modeli dubokog učenja koriste za prepoznavanje obrazaca koji inače verovatno ne bi bili pronađeni analitičkim metodama. Ovi hibridni pristupi imaju koristi od interpretabilnosti i performansi, što ih čini pogodnim za najmodernije instrumente i velika spektroskopska snimanja [17, 18].

5. Obrada svemirskih podataka pomoću AI-a

Veliki i kompleksni skupovi podataka koje moderne misije generišu zahtevaju napredne tehnike procesiranja kako bi se osigurao kvalitet, efikasan način čuvanja, kao i pravovremena analiza podataka. AI igra sve važniju ulogu u procesima poput smanjivanja šuma, data cleaning-a, detekcije anomalija, klasifikacije i obrade podataka na letelici (teleskopu).

5.1. Redukcija šuma

Astronomski podaci su često korumpirani instrumentalnim šumom, kosmičkim zracima i sistemskim efektima koje je jako teško modelovati analitički. *Autoenkodori za uklanjanje šuma* (engl. denoising autoencoders), klasa neuronskih mreža trenirana za rekonstrukciju čistog signala iz šumovitog, su se pokazali kao efikasni pri uklanjanju šuma uz očuvanje astrofizičkih karakteristika. Kevin Schawinski je u svom radu iz 2017. godine demonstrirao da duboke autoenkoderske mreže mogu uspešno ukloniti šum iz snimaka galaksija. Novija istraživanja su proširila ove tehnike na spektroskopske podatke i vremenske serije [20].

5.2. Izoštavanje svetlosnih krivih

Pre detekcije egzoplanete i analize varijabilnosti, svetlosne krive moraju biti očišćene od instrumentalnih trendova i diskontinuiteta. Modeli mašinskog učenja, poput autoenkodera i CNN-ova, mogu naučiti da odvajaju astrofizičku varijabilnost od sistemskog šuma bez eksplicitnih fizičkih modela. U kontekstu podataka sa TESS i Kepler teleskopa, Shallue i Vanderburg su 2018. pokazali da pretprocesiranje bazirano na dubokom učenju povećava performanse tranzitne detekcije. Ovaj trend se nastavlja u novijim cevovodima primenjenim na aktivne misije [4].

5.3. Detekcija teleskopskih anomalija

Svemirski teleskopi rade u teškim uslovima, gde neočekivane anomalije mogu ugroziti kvalitet prikupljenih podataka. Sistemi za detekciju anomalija bazirani na AI-u mogu identifikovati neobične obrasce u telemetrijskim i naučnim podacima u realnom vremenu. Michela Muñoz Fernández je 2017. godine demonstrirala korisnost mašinskog učenja pri detekciji anomalija na svemirskim letelicama, što je postavilo temelj za moderne sisteme [21].

5.4. Klasifikacija svemirskih objekata

Jedna od najstarijih primena veštačke inteligencije u astronomiji je klasifikacija objekata, gde ML modeli kategorizuju zvezde, galaksije i tranzitne događaje na osnovu fotometrijskih i spektroskopskih podataka. CNN-ovi su postigli sjajne performanse u klasifikaciji morfologije galaksija i proceni zvezdanih parametara. Na primer, duboko učenje se u misiji Gaia koristilo za automatsko klasifikovanje milijardi izvora [22, 23].

5.5. Primena AI-a u kompresiji i filtriranju podataka u letelicama

Buduće svemirske misije će imati značajna ograničenja *propusnosti transmisije podataka* (engl. bandwidth). Odatle potiče motivacija iza korišćenja AI-a za kompresiju i filtriranje podataka na samoj letelici. Neuronske mreže mogu prioritizovati naučno vredne opservacije, odbaciti višak podataka i kompresovati snimke uz minimalan gubitak informacija. Ovakve tehnike su posebno važne za buduće misije i eksperimentalne koncepte, dok se kod aktuelnih misija poput Euklida i JWST-a AI primarno koristi u zemaljskim fazama obrade podataka [24].

5.6. Primena AI-a u teleskopima - JWST, Gaia, Euclid

Tehnike obrade podataka bazirane na algoritmima veštačke inteligencije se sve više ugrađuju u cevovode glavnih misija. Nakon obrade podataka sa JWST-a fizički zasnovanim kalibracionim cevovima, algoritmi asistirani mašinskim učenjem se sve češće koriste u naučnim analizama za uklanjanje šuma i spektralnu interpretaciju. Gaia se značajno oslanja na ML za klasifikaciju izvora i analizu varijabilnosti. Euklid koristi duboko učenje za weak-lensing merenja i klasifikaciju morfologije galaksija. Ove misije pokazuju da je AI postao ključna komponenta modernog procesiranja svemirskih podataka, a ne suplementarni alat [25, 26, 27].

6. Izazovi, rizici i interpretabilnost

Bez obzira na brzo prihvatanje veštačke inteligencije u astronomiji, preostali su značajni izazovi koji se moraju prevazići radi pouzdanih i naučno značajnih rezultata. Ovi izazovi se ne odnose samo na performanse modela, već i na interpretabilnost, kvalitet podataka, pristrasnost i reproduktivnost.

6.1. AI modeli su crne kutije

Može se reći da se veliki broj AI modela visokih performansi, a posebno duboke neuronske mreže, ponaša kao „crne kutije“, tj. ovi modeli pružaju prilično ograničen uvid u način donošenja odluka. Ovakav manjak transparentnosti može smanjiti naučno poverenje, posebno kada modeli proizvode neočekivane detekcije ili odbacuju astrofizičke signale bez jasnog obrazloženja. U astronomiji, gde je fizička interpretabilnost ključna, ovakvo ponašanje ograničava mogućnost provere rezultata pomoću uspostavljenih teoretskih modela [28].

6.2. Nepodudaranje sintetičkih i realnih podataka za treniranje

AI modeli se često treniraju na sintetičkim ili simuliranim skupovima podataka, koji aproksimiraju astrofizičke signale u idealnim uslovima. Međutim, realni opservacioni podaci često sadrže nemodelovanu sistematiku, instrumentalne artefakte i uticaje sredine koji nisu prisutni u simulacijama. Ovo nepodudaranje može dovesti do toga da modeli imaju dobre performanse u kontrolisanim uslovima, ali budu loši u generalizaciji stvarnih podataka sa misija [12].

ML sistemi mogu steći nenamerne pristrasnosti prisutne u trening podacima (korelacije vezane za specifične instrumente, strategije opservacije ili zvezdane populacije). Ovo za rezultat može imati AI modele koji sistematski favorizuju određene tipove signala, dok proizvode lažno pozitivne rezultate (koji predstavljaju poznate astrofizičke fenomene). U egzoplanetarnoj nauci, ovo može dovesti do pogrešne klasifikacije zvezdane varijabilnosti ili *pomračenih binarnih sistema*⁶ kao planetarnih tranzita [28].

6.3. Disbalans među klasama (malo planeta, mnogo zvezda)

Jedan od fundamentalnih izazova u detekciji egzoplaneta je ekstremno disbalans klasa: potvrđene planete su retke u odnosu na ogroman broj neplanetarnih svetlosnih krivih. Standardni klasifikacioni modeli mogu postati pristrasni prema većinskoj klasi, postizujući visoku opštu tačnost, dok propuštaju retke, ali naučno vrlo važne planetarne signale. Rešavanje ovog problema zahteva specijalizovane loss funkcije (kvantifikuju „cenu“ tj. grešku između predikcije modela i prave vrednosti), resampling strategije ili rešenja detekcije anomalija [31].

6.4. Alati za interpretaciju

Kako bi se ublažilo ponašanje nalik crnoj kutiji, u astronomiji se sve više koriste tehnike interpretabilnosti (npr. Grad-CAM) i tzv. feature attribution metode (alati za razumevanje uzroka donošenja određene odluke AI modela). Ovi alati ističu regione slike ili segmente svetlosne krive koji utiču na predikcije modela, što astronomima omogućava da potvrde da se AI sistemi fokusiraju na fizički smislene

⁶Pomraćeni binarni sistemi (engl. eclipsing binary systems) predstavljaju parove zvezda koje orbitiraju jedna drugu u ravni koplanarnoj sa Zemljom, što dovodi do toga da jedna zvezda periodično blokira drugu. Ovo izaziva smanjenja u totalnom intenzitetu svetlosti sistema tj. svetlosnoj krivoj. Zanimljivo je da binarni sistemi čine većinu zvezdanih sistema vidljivih sa Zemlje (procenjeno na oko 85%) [29, 30].

karakteristike, a ne šum ili artefakte. Dakle, metode interpretabilnosti rade kao most između učenja iz podataka i fizičkog razumevanja [32, 33].

6.5. Potreba za reproduktivnošću

Iako je reproduktivnost temelj naučnog istraživanja, ona je i dalje izazov u astronomiji vođenoj veštačkom inteligencijom. Razlike u procesiranju podataka, inicijalizaciji modela i procedurama treniranja mogu dovesti do nedoslednih rezultata u studijama. Osiguravanje reproduktivnosti zahteva zahteva otvorene skupove podataka, transparentne metodologije, deljen kôd i standardizovane testove, posebno kako AI modeli postaju još kompleksniji i količina podataka nastavlja da raste [28].

7. Budućnost i zaključak

Kako astronomski skupovi podataka postaju sve veći i kompleksniji, očekuje se da će veštačka inteligencija imati fundamentalnu ulogu u transformisanju postojećih metoda istraživanja univerzuma. Budući napredak će se nadovezivati na sadašnje uspehe i proširiti primenu AI-a na nove domene, omogućavajući naučni uvid i otkrića nedostižna korišćenjem tradicionalnih metoda.

Jedan od glavnih smerova za buduća istraživanja je razvijanje i usvajanje tzv. temeljnih modela (engl. *foundational models*). Ovo su veliki, unapred trenirani modeli koji mogu biti fino podešeni za više *nizvodnih* (engl. *downstream*) zadataka (poput detekcije egzoplaneta, tranzitne klasifikacije i spektralne analize) koristeći minimalnu količinu podataka specijalizovanih za konkretan zadatak. U širem širem AI istraživanju, temeljni modeli su pokazali sposobnost generalizacije na više domena, a njihova adaptacija na multimodalne astronomske podatke (snimanje, spektroskopija, vremenske serije) mogla bi da ujedini odvojene cevovode za analizu u jedinstveno skalabilno rešenje. Rane diskusije u literaturi ističu potrebu za kolaborativnim razvojem ovih modela unutar astronomske zajednice, kako bi se iskoristili multimodalni podaci visokog kvaliteta i izbegla fragmentacija napora [34].

Još jedna obećavajuća oblast je dalja integracija AI-a sa *višekanalnom astronomijom* (engl. *multi-messenger astronomy*), gde se opservacije sa fotometrijskih, spektroskopskih, gravitacionotalasnih i visokoenergetskih detektora kombinuju, kako bi se došlo do holističkog razumevanja kosmičkih pojava. Recenzije o veštačkoj inteligenciji u astronomiji vremenskog domena (engl. *time-domain astronomy*) ističu kako mašinsko učenje može obraditi milione prolaznih upozorenja, automatizovati određivanje prioriteta praćenja i klasifikovati pojave sa minimalnom ljudskom intervencijom. Ovo postaje sve potrebnije, jer ima sve više postrojenja koja generišu ogromne količine podataka [35].

Napredak na poljima objašnjive veštačke inteligencije (XAI)⁷ i alata za kolaboraciju čoveka i AI-a biće ključan za održavanje kompleksnih modela naučno interpretabilnim i pouzdanim. Istraživanja ističu potrebu za transparentnošću, interpretabilnošću i reproduktivnošću u astronomiji zasnovanoj na AI-u radi borbe protiv pristrasnosti i izgradnje poverenja astronomske zajednice u automatizovana otkrića. Očekuje se da će se brojne tehnike za validaciju predikcija modela poboljšati [1, 28].

AI će takođe omogućiti nove opservacione strategije, kao i novi dizajn misija. Autonomne letelice opremljene AI sistemima bi mogle donositi odluke o prioritizaciji podataka, odgovoru na anomalije i adaptivnom planiranju u realnom vremenu, što bi značajno smanjilo oslanjanje na kontrolu sa zemlje. Rani koncepti za svemirske platforme predvođene veštačkom inteligencijom (uključujući AI sisteme za procesiranje podataka u orbiti⁸) ilustruju kako granica između prikupljanja i analize podataka može nestati tokom budućih misija [37].

Dakle, AI je već demonstrirao transformativni uticaj na raznim poljima opservacione astronomije, od egzoplaneta, sve do klasifikacije tranzita i šire. Kako se metodologija bude razvijala (posebno u kontekstu velikih temeljnih modela, objašnjivosti, višemodalne integracije i autonomnih instrumenata), sinergija između AI-a i astronomije će se produbiti. Buduća istraživanja moraju izbalansirati inovaciju sa transparentnošću i reproduktivnošću, kako bi se osiguralo da AI ostane kako moćan alat, tako i naučno rigorozan partner u potrazi za razumevanjem kosmosa.

⁷Explainable AI - skup procesa i metoda koje omogućavaju ljudskim korisnicima da razumeju i veruju rezultatima generisanim pomoću ML algoritama [36].

⁸U trenutku pisanja ovog rada, Kina i Amerika se nadmeću u lansiranju prvog AI superračunara u orbitu. Premeštanje AI infrastrukture u svemir bi moglo biti značajno za uštedu vode i energije koju AI sistemi koriste. Takođe, velike kompanije (SpaceX, Blue Origin, Google) ulažu stotine milijardi dolara u orbitirajuće AI sisteme.

Literatura

- [1] S. G. Djorgovski, A. Mahabal, M. J. Graham, K. Polsterer, and A. Krone-Martins, “Applications of ai in astronomy,” *arXiv preprint arXiv:2212.01493*, 2022.
- [2] N. Hartono and S. Carney, “Kepler exoplanet mission.” <https://www.jpl.nasa.gov/missions/kepler/>, 2024. Datum pristupa: 15.12.2025.
- [3] J. Kazmierczak, “Tess (transiting exoplanet survey satellite).” <https://science.nasa.gov/mission/tess/>, 2025. Datum pristupa: 23.12.2025.
- [4] C. J. Shallue and A. Vanderburg, “Identifying exoplanets with deep learning: A five-planet resonant chain around kepler-80 and an eighth planet around kepler-90,” *The Astronomical Journal*, vol. 155, no. 2, p. 94, 2018.
- [5] S. Carney, “What’s a transit?.” <https://science.nasa.gov/exoplanets/whats-a-transit/>, 2024. Datum pristupa: 15.12.2025.
- [6] S. Carney, “Exoplanets.” <https://science.nasa.gov/exoplanets/>, 2025. Datum pristupa: 15.12.2025.
- [7] “Color-shifting stars: The radial-velocity method.” <https://www.planetary.org/articles/color-shifting-stars-the-radial-velocity-method>, 2020. Datum pristupa: 17.12.2025.
- [8] S. Sabia, “Spectroscopy 101 – introduction.” <https://science.nasa.gov/mission/webb/science-overview/science-explainers/spectroscopy-101-introduction/>, 2025. Datum pristupa: 17.12.2025.
- [9] D. R. Soderblom and J. R. King, “Solar-type stars: Basic information on their classification and characterization,” *Solar Analogs: Characteristics and Optimum Candidates.*, p. 41, 1998.
- [10] K. A. Pearson, L. Palafox, and C. A. Griffith, “Searching for exoplanets using artificial intelligence,” *Monthly Notices of the Royal Astronomical Society*, vol. 474, no. 1, pp. 478–491, 2018.
- [11] T. S. F. Luz, R. A. S. Braga, and E. R. Ribeiro, “Assessment of ensemble-based machine learning algorithms for exoplanet identification,” *Electronics*, vol. 13, no. 19, 2024.
- [12] R. Karimi, M. Mousavi-Sadr, M. H. Z. Haghighi, and F. S. Tabatabaei, “Machine learning for exoplanet detection: A comparative analysis using kepler data,” *arXiv preprint arXiv:2508.09689*, 2025.
- [13] D. Moreno-Cartagena, G. Cabrera-Vives, A. M. M. Arancibia, P. Protopapas, F. Förster, M. Cateilan, A. Bayo, P. A. Estévez, P. Sánchez-Sáez, F. E. Bauer, *et al.*, “Image-based multi-survey classification of light curves with a pre-trained vision transformer,” *arXiv preprint arXiv:2507.11711*, 2025.
- [14] A. Akhmetali, A. Zhunuskanov, A. Sakan, M. Zaidyn, T. Namazbayev, D. Turlykozhaeva, and N. Ussipov, “Luminis stellarum et machina: Applications of machine learning in light curve analysis,” *arXiv preprint arXiv:2504.10038*, 2025.
- [15] D. Xie, Y. Wang, F. Liu, and W. Sun, “Deep learning to classify exoplanet light curves in kepler and tess,” *Research in Astronomy and Astrophysics*, vol. 25, no. 10, p. 104004, 2025.
- [16] “Circumstellar disc.” <https://esahubble.org/wordbank/circumstellar-disc/>. Datum pristupa: 04.01.2026.
- [17] E. O. Garvin, M. J. Bonse, J. Hayoz, G. Cugno, J. Spiller, P. A. Patapis, D. P. dit de la Roche, R. Nath-Ranga, O. Absil, N. F. Meinshausen, *et al.*, “Machine learning for exoplanet detection in high-contrast spectroscopy-revealing exoplanets by leveraging hidden molecular signatures in cross-correlated spectra with convolutional neural networks,” *Astronomy & Astrophysics*, vol. 689, p. A143, 2024.

- [18] R. Nath-Ranga, O. Absil, V. Christiaens, and E. O. Garvin, “Machine learning for exoplanet detection in high-contrast spectroscopy-combining cross-correlation maps and deep learning on medium-resolution integral-field spectra,” *Astronomy & Astrophysics*, vol. 689, p. A142, 2024.
- [19] Z. L. De Beurs, A. Vanderburg, C. J. Shallue, X. Dumusque, A. C. Cameron, C. Leet, L. A. Buchhave, R. Cosentino, A. Ghedina, R. D. Haywood, *et al.*, “Identifying exoplanets with deep learning. iv. removing stellar activity signals from radial velocity measurements using neural networks,” *The Astronomical Journal*, vol. 164, no. 2, p. 49, 2022.
- [20] K. Schawinski, C. Zhang, H. Zhang, L. Fowler, and G. K. Santhanam, “Generative adversarial networks recover features in astrophysical images of galaxies beyond the deconvolution limit,” *Monthly Notices of the Royal Astronomical Society: Letters*, vol. 467, no. 1, pp. L110–L114, 2017.
- [21] M. M. Fernández, Y. Yue, and R. Weber, “Telemetry anomaly detection system using machine learning to streamline mission operations,” in *2017 6th International Conference on Space Mission Challenges for Information Technology (SMC-IT)*, pp. 70–75, IEEE, 2017.
- [22] A. McQuillan, T. Mazeh, and S. Aigrain, “Rotation periods of 34,030 kepler main-sequence stars: the full autocorrelation sample,” *The Astrophysical Journal Supplement Series*, vol. 211, no. 2, p. 24, 2014.
- [23] L. Delchambre, C. A. Bailer-Jones, I. Bellas-Velidis, R. Drimmel, D. Garabato, R. Carballo, D. Hatzidimitriou, D. J. Marshall, R. Andrae, C. Dafonte, *et al.*, “Gaia data release 3-apsis. iii. non-stellar content and source classification,” *Astronomy & Astrophysics*, vol. 674, p. A31, 2023.
- [24] F. Ortiz, V. Monzon Baeza, L. M. Garces-Socarras, J. A. Vásquez-Peralvo, J. L. Gonzalez, G. Fontanesi, E. Lagunas, J. Querol, and S. Chatzinotas, “Onboard processing in satellite communications using ai accelerators,” *Aerospace*, vol. 10, no. 2, p. 101, 2023.
- [25] T. E. S. Agency, “Gaia data processing and analysis consortium overview.” <https://www.cosmos.esa.int/web/gaia/dpac#>, 2022. Datum pristupa: 03.01.2026.
- [26] T. E. S. Agency, “Euclid overview.” https://www.esa.int/Science_Exploration/Space_Science/Euclid_overview, 2023. Datum pristupa: 03.01.2026.
- [27] “Jwst science calibration pipeline.” <https://jwst-docs.stsci.edu/jwst-science-calibration-pipeline>. Datum pristupa: 25.12.2025.
- [28] M. Lieu, “A comprehensive guide to interpretable ai-powered discoveries in astronomy,” *Universe*, vol. 11, no. 6, p. 187, 2025.
- [29] H. M. Boffin and D. Jones, “The importance of binary stars,” *arXiv preprint arXiv:2411.18470*, 2024.
- [30] “Eclipsing binary variables.” <https://lweb.cfa.harvard.edu/sdu/eclipsingbinaries.html>. Datum pristupa: 04.01.2026.
- [31] Z. Hosenie, R. Lyon, B. Stappers, A. Mootoovaloo, and V. McBride, “Imbalance learning for variable star classification,” *Monthly Notices of the Royal Astronomical Society*, vol. 493, pp. 6050–6059, 03 2020.
- [32] M. Atemkeng, C. Chuma, S. Zaza, C. Nunhokee, and O. Smirnov, “A benchmark analysis of saliency-based explainable deep learning methods for the morphological classification of radio galaxies,” *arXiv preprint arXiv:2502.17207*, 2025.
- [33] S. Ye, W.-Y. Cui, Y.-B. Li, A.-L. Luo, and H. R. Jones, “Deep learning interpretability analysis for carbon star identification in gaia dr3,” *Astronomy & Astrophysics*, vol. 697, p. A107, 2025.
- [34] M. J. Smith and J. E. Geach, “Astronomia ex machina: a history, primer and outlook on neural networks in astronomy,” *Royal Society Open Science*, vol. 10, no. 5, p. 221454, 2023.

- [35] Z.-N. Wang, D.-C. Qiang, and S. Yang, “Artificial intelligence revolutionizing time-domain astronomy,” *Universe*, vol. 11, no. 11, p. 355, 2025.
- [36] “What is explainable ai?.” <https://www.ibm.com/think/topics/explainable-ai>. Datum pristupa: 04.01.2026.
- [37] E. Rayne, “China is building a new kind of supercomputer above earth.” <https://www.popularmechanics.com/technology/infrastructure/a69735521/china-space-ai/>, 2025. Datum pristupa: 03.01.2026.